

Politechnika Warszawska

Wydział Matematyki
i Nauk Informacyjnych

Sieci neuronowe

Rozpoznawanie cyfr ze zbioru MNIST z użyciem perceptronu wielowarstwowego

Raport z części drugiej

Zespół:

Adam Grącikowski

Prowadzący:

dr inż. Maksymilian Bujok

mgr inż. Grzegorz Zakrzewski

Oświadczam, że niniejsza praca, stanowiąca podstawę do uznania osiągnięcia efektów uczenia się z przedmiotu *Sieci neuronowe*, została wykonana samodzielnie.

Warszawa, 21 października 2026

Streszczenie

Perceptron wielowarstwowy, który został zaimplementowany od podstaw w pierwszej części projektu, zastosowano do rozpoznawania odręcznie pisanych cyfr ze zbioru MNIST. W stosunku do implementacji z pierwszej części projektu nie dodano do niego nowych funkcjonalności. Zmieniono jedynie konfigurację sieci i uczenia.

Konfigurację sieci dobrano w pięciu kolejnych badaniach, z których każde zmieniało jeden czynnik: normalizację wejść, architekturę, funkcję aktywacji, optymalizator ze współczynnikiem uczenia i rozmiar paczki. Każdy wariant uczono dla 5 ziaren generatora liczb losowych na podzbiorze 10 000 obrazów uczących z wczesnym zatrzymaniem, a warianty porównywano na wydzielonym z niego zbiorze walidacyjnym. Zbioru testowego użyto tylko do oceny sieci końcowej.

Najsilniej na wynik wpływały liczba neuronów warstwy ukrytej i funkcja aktywacji. Jedna warstwa z 512 neuronami osiągnęła średnio 95,16% dokładności walidacyjnej, wobec 92,70% dla 32 neuronów, a dodatkowe warstwy nie poprawiały wyniku. Funkcje ReLU i leaky ReLU dawały o ponad punkt procentowy wyższą dokładność niż funkcja sigmoidalna i tanh. Pozostałe czynniki zmieniały wynik w granicach rozrzutu między ziarnami.

Sieć 784-512-10 z ReLU, normalizacją min-max, optymalizatorem Adam i paczką 32, uczona na pełnym zbiorze uczącym, osiągnęła na zbiorze testowym $(97{,}91 \pm 0{,}15)\%$ dokładności dla 5 ziaren. Zgłoszona sieć, uczona z ziarnem ustalonym przed uczeniem, osiągnęła 97,74%.

Spis treści

1 Wstęp **3**
1.1 Cel i zakres . . . 3
1.2 Struktura raportu . . . 3

2 Opis problemu **4**
2.1 Zbiór MNIST . . . 4
2.2 Wymagania . . . 4

3 Sieć i implementacja **5**
3.1 Sieć i uczenie . . . 5
3.2 Zmiany względem części pierwszej . . . 5

4 Metodyka eksperymentów **6**
4.1 Strojenie . . . 6
4.2 Uczenie końcowe . . . 7

5 Wyniki strojenia **8**
5.1 Normalizacja wejść . . . 8
5.2 Architektura sieci . . . 9
5.3 Funkcja aktywacji . . . 9
5.4 Optymalizator . . . 10
5.5 Rozmiar paczki . . . 11
5.6 Konfiguracja wybrana w strojeniu . . . 12

6 Sieć końcowa **13**
6.1 Wyniki dla pięciu ziaren . . . 13
6.2 Zgłoszona sieć . . . 13

7 Podsumowanie i wnioski **17**
7.1 Wnioski . . . 17
7.2 Ograniczenia . . . 17

Bibliografia **18**

A Odtworzenie wyników **19**

1 Wstęp

W rozdziale przedstawiono cel i zakres drugiej części projektu oraz strukturę raportu.

1.1 Cel i zakres

W pierwszej części projektu zaimplementowano od podstaw, bez bibliotek implementujących sieci neuronowe, perceptron wielowarstwowy uczony propagacją wsteczną błędu i zbadano go w zadaniach regresji i klasyfikacji na prostych zbiorach danych [1]. Celem części drugiej było użycie tej implementacji do rozpoznawania odręcznie pisanych cyfr ze zbioru MNIST [2]. Implementacji nie wolno było rozszerzać o nowe funkcjonalności, więc dostosowanie sieci do zadania polegało wyłącznie na doborze jej parametrów i parametrów uczenia.

Wnioski z części pierwszej wskazywały, że przy takim zadaniu potrzebne będą zbiór walidacyjny, wczesne zatrzymanie i dobór współczynnika uczenia, a porównania wariantów powinny opierać się na wielu ziarnach generatora liczb losowych [1, rozdz. 10.2]. Dlatego konfigurację sieci dobrano w badaniach strojenia na podzbiorze zbioru uczącego, porównując warianty na wydzielonym z niego zbiorze walidacyjnym dla kilku ziaren. Wybraną konfigurację nauczono, także dla kilku ziaren, na pełnym zbiorze uczącym, a zbioru testowego użyto tylko do oceny nauczonych sieci. Do oceny zgłoszono jedną z nich, wraz z konfiguracją i ziarnem pozwalającymi powtórzyć jej uczenie.

1.2 Struktura raportu

W rozdziale 2 opisano zbiór MNIST, miary jakości i wymagania części drugiej. W rozdziale 3 przypomniano budowę sieci i programu z części pierwszej oraz wymieniono wprowadzone zmiany. Rozdział 4 opisuje sposób strojenia i uczenia końcowego, rozdział 5 wyniki badań strojenia, a rozdział 6 wyniki sieci końcowej na zbiorze testowym. Rozdział 7 podsumowuje wnioski i ograniczenia badań. W dodatku A podano polecenia i konfigurację potrzebne do odtworzenia wyników.

2 Opis problemu

W rozdziale opisano zbiór MNIST, sposób oceny klasyfikatora oraz wymagania postawione w części drugiej projektu.

2.1 Zbiór MNIST

Zbiór MNIST (ang. *Modified National Institute of Standards and Technology*) zawiera obrazy odręcznie pisanych cyfr [2]. Każdy obraz ma 28×28 pikseli w skali szarości o wartościach całkowitych od 0 (tło) do 255, a cyfra jest przeskalowana do jednakowego rozmiaru i wyśrodkowana w polu obrazu. Zadaniem jest klasyfikacja: wejściem sieci jest wektor $\mathbf{x} \in \mathbb{R}^{784}$ jasności pikseli obrazu, a odpowiedzią jedna z $K = 10$ klas odpowiadających cyfrom od 0 do 9.

Zbiór dzieli się na 60 000 obrazów uczących i 10 000 testowych. Liczności klas przedstawiono w Tabeli 1.

Tabela 1: Liczba obrazów każdej cyfry w zbiorze uczącym i testowym MNIST oraz jej udział w zbiorze.

Cyfra	Zbiór uczący		Zbiór testowy	
	Liczba	Udział [%]	Liczba	Udział [%]
0	5923	9,87	980	9,80
1	6742	11,24	1135	11,35
2	5958	9,93	1032	10,32
3	6131	10,22	1010	10,10
4	5842	9,74	982	9,82
5	5421	9,04	892	8,92
6	5918	9,86	958	9,58
7	6265	10,44	1028	10,28
8	5851	9,75	974	9,74
9	5949	9,91	1009	10,09
suma	60 000		10 000	

Obrazy są rzadkie: około 81% wartości pikseli zbioru uczącego to zera. Ponadto 67 pikseli przy brzegu obrazu ma wartość 0 we wszystkich obrazach uczących. Takie wejście jest stałe także po normalizacji, więc wagi łączące je z pierwszą warstwą sieci nie otrzymują gradientu i pozostają równe wartościom początkowym. Rzadkość pikseli ma znaczenie przy wyborze normalizacji wejść (podrozdział 5.1) i przy interpretacji wag pierwszej warstwy (podrozdział 6.2).

Miarą jakości klasyfikatora jest dokładność, czyli odsetek poprawnie sklasyfikowanych obrazów, zdefiniowana tak samo jak w części pierwszej [1, rozdz. 2.1]. Uzupełnia ją macierz pomyłek (ang. *confusion matrix*), której element w wierszu k i kolumnie l jest liczbą obrazów klasy k zaklasyfikowanych jako klasa l. Elementy poza przekątną wskazują, które cyfry sieć ze sobą myli.

2.2 Wymagania

Treść zadania stawia części drugiej projektu następujące wymagania:

- implementacji z części pierwszej nie wolno rozszerzać o nowe funkcjonalności, a zmieniać się mogą tylko parametry sieci i uczenia (rozdział 3),
- w uczeniu wolno korzystać tylko ze zbioru uczącego, a zbiór testowy służy wyłącznie do oceny nauczonej sieci (rozdział 4),
- wstępne eksperymenty mogą korzystać z podzbioru danych uczących (podrozdział 4.1),
- uczenie zgłoszonej sieci musi być powtarzalne, więc należy podać wszystkie parametry programu i ziarno (dodatek A),
- wynik uczenia zależy od ziarna, więc powtarzalność wyników należy sprawdzić dla wielu ziaren (rozdział 6).

3 Sieć i implementacja

W rozdziale przypomniano budowę sieci i programu z części pierwszej oraz wymieniono zmiany wprowadzone na potrzeby części drugiej.

3.1 Sieć i uczenie

Do rozpoznawania cyfr użyto perceptronu wielowarstwowego zaimplementowanego od podstaw w części pierwszej projektu. Jego model, funkcje aktywacji i straty, propagację wsteczną, metody optymalizacji i inicjalizacji wag opisano w raporcie z tej części [1, rozdz. 3]. Warstwy sieci są macierzami wag i wektorami biasów, a uczenie polega na minimalizacji funkcji straty metodą spadku wzdłuż gradientu na losowo tasowanych paczkach (ang. *batch*) próbek. W rozpoznawaniu cyfr wejściem sieci jest 784 pikseli obrazu, a warstwa wyjściowa ma 10 neuronów z funkcją softmax i jest uczona z entropią krzyżową.

Wszystkie parametry zmieniane w części drugiej były dostępne w konfiguracji już w części pierwszej: funkcje aktywacji warstw ukrytych (sigmoidalna, tanh, ReLU i leaky ReLU), inicjalizacja wag Xaviera i He, optymalizatory SGD, SGD z momentum i Adam [1, rozdz. 3.2, 3.5, 3.6], normalizacja wejść osobno dla każdej kolumny (standaryzacja albo przekształcenie zakresu do przedziału $[0, 1]$, nazywane dalej normalizacją min-max), losowy podzbiór zbioru uczącego, wydzielenie z niego zbioru walidacyjnego oraz wczesne zatrzymanie na stracie walidacyjnej [1, rozdz. 4.3, 4.4]. Parametry normalizacji wyznacza się tylko na części uczącej, a wczesne zatrzymanie przywraca sieć z epoki o najmniejszej stracie walidacyjnej. Zbiór testowy jest po każdej epoce tylko oceniany i nie wpływa na przebieg uczenia.

Program składa się z warstwy obliczeniowej w języku Rust, która uczy sieć i zapisuje wyniki, oraz warstwy prezentacji w języku Python, która tworzy z nich wykresy i zestawienia. Pojedynczy eksperyment opisuje plik `config.toml`, a badanie, czyli zbiór eksperymentów różniących się wybranymi parametrami i ziarnem, plik `study.toml` [1, rozdz. 4.1, 4.7]. Przebieg uczenia jest w pełni wyznaczony przez konfigurację i ziarno generatora liczb losowych, więc ponowne uczenie daje sieć identyczną co do bitu [1, rozdz. 4.5]. Polecenia i konfigurację potrzebne do powtórzenia uczenia zgłoszonej sieci podano w dodatku A.

3.2 Zmiany względem części pierwszej

Kod sieci, uczenia, przygotowania danych i konfiguracji jest taki sam jak w części pierwszej. Wczytywanie plików CSV z dowolną liczbą cech i klasyfikacja do dowolnej liczby klas obsługują zbiór MNIST bez zmian. Dodano jedynie narzędzia wokół sieci, które nie wpływają na przebieg uczenia:

- polecenie `mnist` warstwy prezentacji, które pobiera pliki zbioru w oryginalnym formacie binarnym IDX, sprawdza ich sumy kontrolne SHA-256 i zapisuje je jako pliki CSV z surowymi wartościami pikseli od 0 do 255 (normalizację określa konfiguracja eksperymentu),
- klucz `split` w pliku `study.toml`, który wskazuje zbiór, na którym porównuje się warianty badania. Domyślnie jest to zbiór testowy, a w badaniach części drugiej zbiór walidacyjny,
- dwa wykresy dla wejść będących kwadratowymi obrazami: najpewniejsze błędne klasyfikacje na zbiorze testowym oraz wagi pierwszej warstwy przedstawione jako obrazy.

4 Metodyka eksperymentów

W rozdziale opisano, jak dobrano konfigurację sieci na podzbiorze zbioru uczącego bez użycia zbioru testowego oraz jak oceniono wybraną konfigurację po uczeniu na pełnym zbiorze uczącym.

4.1 Strojenie

Konfigurację sieci dobrano w serii badań, z których każde zmienia jeden czynnik (ang. *one-factor-at-a-time*). Badania przeprowadzono kolejno, a każde zaczynało od konfiguracji zawierającej poziomy wybrane w badaniach poprzednich. Kolejność badań i poziomy czynników przedstawiono w Tabeli 2. Funkcja aktywacji zmienia się razem z dobraną do niej inicjalizacją wag [1, rozdz. 3.6]. Współczynniki uczenia SGD i SGD z momentum dobrano tak, aby kroki obu metod były porównywalne. Przy współczynniku momentum $\mu = 0{,}9$ krok w kierunku stałego gradientu rośnie do około $1/(1-\mu) = 10$ razy większego niż w SGD [3, rozdz. 8.3.2], więc $\eta = 0{,}01$ odpowiada w SGD współczynnikowi $\eta = 0{,}1$. Dla optymalizatora Adam sprawdzono domyślną wartość $\eta = 0{,}001$ [4] oraz wartości około trzy razy mniejszą i większą. W badaniu rozmiaru paczki maksymalna liczba epok jest stała, więc mniejsza paczka oznacza więcej iteracji w każdej epoce.

Tabela 2: Badania strojenia w kolejności ich przeprowadzenia. Architekturę podano jako liczby neuronów kolejnych warstw ukrytych, a w nawiasach współczynniki uczenia η.

Nr	Czynnik	Poziomy	Liczba poziomów
1	normalizacja wejść	min-max, standaryzacja	2
2	architektura	brak warstw ukrytych, 32, 128, 512, 128-64, 256-128, 128-128-128	7
3	funkcja aktywacji	funkcja sigmoidalna i tanh z inicjalizacją Xaviera, ReLU i leaky ReLU z $\alpha = 0{,}01$ z inicjalizacją He	4
4	optymalizator	SGD (0,1), SGD z momentum $\mu = 0{,}9$ (0,01), Adam (0,0003, 0,001 i 0,003)	5
5	rozmiar paczki	16, 32, 64 i 128	4

Konfigurację, od której zaczęło się pierwsze badanie, przedstawiono w Tabeli 3. Każdy wariant uczono na stratyfikowanym losowym podzbiorze 10 000 obrazów zbioru uczącego. Z podzbioru wydzielono stratyfikowany zbiór walidacyjny 2000 obrazów, a na pozostałych 8000 obrazach uczono sieć. Każdy wariant uczono dla 5 ziaren generatora liczb losowych, od 1 do 5. Ziarno wyznacza nie tylko inicjalizację wag i kolejność paczek, ale także wylosowany podzbiór i podział na część uczącą i walidacyjną, więc rozrzut wyników między ziarnami obejmuje również zmienność danych. Uczenie trwało co najwyżej 30 epok. Wczesne zatrzymanie przerywało je, gdy strata walidacyjna nie zmalała przez 5 kolejnych epok, i przywracało sieć z epoki o najmniejszej stracie walidacyjnej [3, rozdz. 7.8]. Metryki eksperymentu pochodzą z tej epoki. Wszystkie 110 eksperymentów strojenia zakończyło się wczesnym zatrzymaniem przed limitem epok. Wariant z poziomami wybranymi we wcześniejszych badaniach występuje w kilku kolejnych badaniach i dla tych samych ziaren daje w nich identyczne wyniki.

Tabela 3: Konfiguracja na początku strojenia i konfiguracja uczenia końcowego. Gwiazdką oznaczono parametry zmieniane w strojeniu (Tabela 2).

Parametr	Początek strojenia	Uczenie końcowe
obrazy uczące / walidacyjne	8000 / 2000	54 000 / 6000
normalizacja wejść*	min-max	min-max
warstwy ukryte*	128	512
aktywacja warstw ukrytych*	ReLU	ReLU
inicjalizacja wag*	He	He
biasy	tak	tak
aktywacja wyjściowa	softmax	softmax
funkcja straty	entropia krzyżowa	entropia krzyżowa
optymalizator*	Adam	Adam
współczynnik uczenia η*	0,001	0,001
rozmiar paczki*	32	32
iteracje w epoce	250	1688
maksymalna liczba epok	30	50
cierpliwość wczesnego zatrzymania	5 epok	5 epok
ziarna	1–5	1–5

Warianty porównuje się na podstawie dokładności walidacyjnej, podając jej średnią i próbkowe odchylenie standardowe po 5 ziarnach. Wybierano poziom o największej średniej. Tak jak w części pierwszej [1, rozdz. 6.3], różnice porównywalne z odchyleniem standardowym między ziarnami opisuje się jako słabe. Wyniki każdego badania przedstawiono na wykresie wyników ziaren, na którym każde ziarno jest punktem, a średnia z odchyleniem standardowym odcinkiem, oraz w razie potrzeby na wykresie dokładności walidacyjnej po kolejnych epokach (średnia z pasem odchylenia standardowego). Zbiór testowy był w trakcie strojenia oceniany przez program, ale jego wyników nie używano przy wyborach i nie przedstawiono ich w rozdziale 5.

4.2 Uczenie końcowe

Konfigurację wybraną w strojeniu nauczono na pełnym zbiorze uczącym (Tabela 3). Z 60 000 obrazów wydzielono stratyfikowany zbiór walidacyjny 6000 obrazów, używany tylko do wczesnego zatrzymania, a sieć uczono na pozostałych 54 000. Maksymalną liczbę epok zwiększono do 50, a pozostałe ustawienia uczenia nie zmieniły się. Uczenie przeprowadzono dla 5 ziaren, od 1 do 5. Zbiór testowy nie wpływał na przebieg uczenia ani na żaden wybór, a jego wyniki odczytano po zakończeniu uczenia. Wynik podaje się jako średnią i próbkowe odchylenie standardowe dokładności testowej.

Sieć zgłoszoną do oceny uczono z ziarnem 1. Ziarno ustalono przed uczeniem, a nie wybrano na podstawie wyniku testowego, więc dokładność testowa zgłoszonej sieci nie jest zawyżona przez wybór najlepszego z kilku uczeń. Zgłoszona sieć jest tym samym uczeniem co ziarno 1 z pięciu opisanych wyżej.

5 Wyniki strojenia

W rozdziale przedstawiono wyniki pięciu badań strojenia z Tabeli 2 w kolejności ich przeprowadzenia. Tabele podają średnią i odchylenie standardowe dokładności na części uczącej i walidacyjnej po 5 ziarnach oraz średni numer epoki o najmniejszej stracie walidacyjnej, z której pochodzi sieć zwrócona przez wczesne zatrzymanie. Dokładność walidacyjną odczytuje się w tej epoce, a nie w epoce największej dokładności, więc krzywe dokładności po epokach mogą wychodzić ponad wartości z tabel. Wariant złożony z poziomów wybranych w kolejnych badaniach (sieć 512 z ReLU, Adam z $\eta = 0{,}001$, paczka 32) występuje w badaniach od drugiego do piątego i za każdym razem daje ten sam wynik, $(95{,}16 \pm 0{,}39)\%$.

We wszystkich badaniach średnia dokładność ucząca wariantów z warstwami ukrytymi przekracza 97%, a średnia walidacyjna nie przekracza 95,2%. Przy 8000 obrazach uczących sieci szybko dopasowują się do części uczącej, a strata walidacyjna przestaje maleć po kilku do kilkunastu epokach.

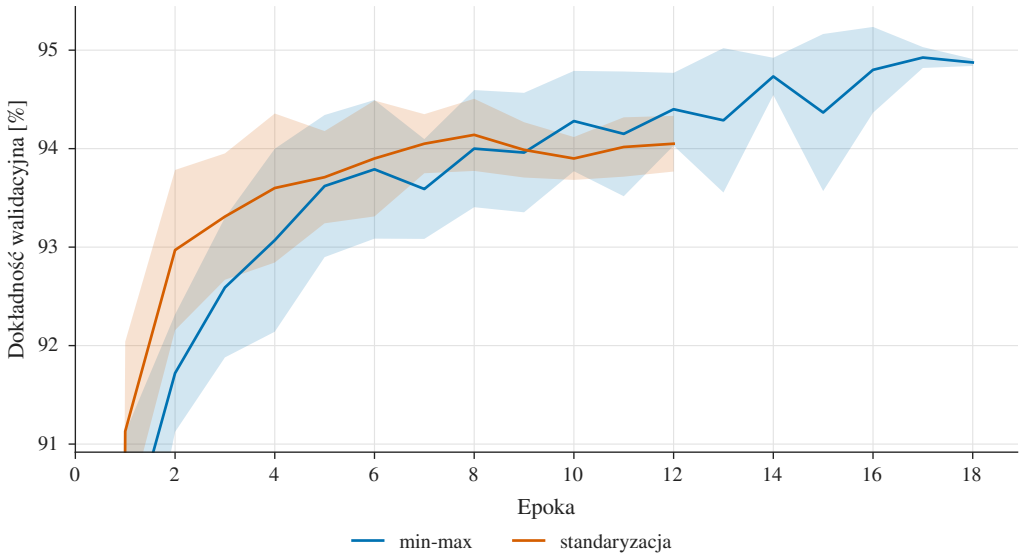
5.1 Normalizacja wejść

Wyniki przedstawiono w Tabeli 4 i na Rysunku 1. Normalizacja min-max daje średnio o 0,45 punktu procentowego większą dokładność walidacyjną niż standaryzacja. Różnica jest porównywalna z odchyleniem standardowym między ziarnami, więc efekt jest słaby. Przy standaryzacji strata walidacyjna osiąga minimum wcześniej, średnio w epoce 5,4 wobec 10,2, a dokładność walidacyjna przestaje rosnąć na niższym poziomie (Rysunek 1).

Standaryzacja dzieli każdy piksel przez jego odchylenie standardowe w części uczącej, które dla pikseli rzadko różnych od zera jest małe. Piksel niezerowy w jednym z 8000 obrazów uczących przyjmuje po standaryzacji wartość $\sqrt{7999} \approx 89{,}4$. W części walidacyjnej od 16% do 19% obrazów (zależnie od ziarna) ma co najmniej jeden piksel o wartości bezwzględnej większej niż 10. Przy normalizacji min-max wejścia uczące leżą w przedziale $[0, 1]$, a takich obrazów walidacyjnych jest co najwyżej 0,6%. Gorszy wynik standaryzacji jest zgodny z tą różnicą skali wejść. Wybrano normalizację min-max.

Tabela 4: Wyniki badania normalizacji wejść (sieć 128, 5 ziaren).

Normalizacja	Dokładność [%]		Najlepsza
	ucząca	walidacyjna	epoka
min-max	$99{,}47 \pm 0{,}65$	$94{,}35 \pm 0{,}61$	10,2
standaryzacja	$99{,}64 \pm 0{,}52$	$93{,}90 \pm 0{,}18$	5,4



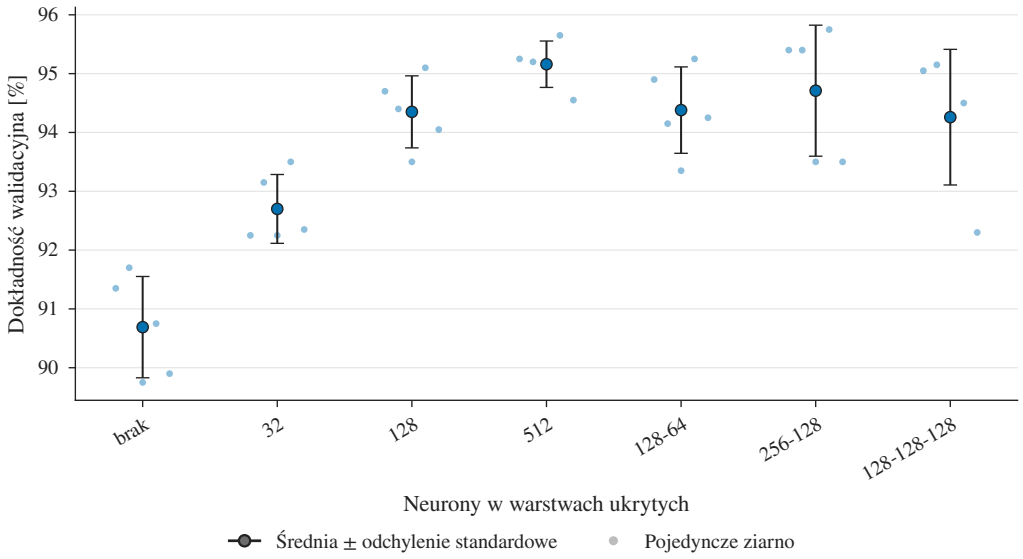
Rysunek 1: Dokładność walidacyjna po kolejnych epokach w badaniu normalizacji wejść: średnia po ziarnach z pasem jednego odchylenia standardowego. Uczenie każdego ziarna kończy się po wczesnym zatrzymaniu, więc w późnych epokach średnia obejmuje tylko trwające jeszcze uczenia.

5.2 Architektura sieci

Wyniki przedstawiono w Tabeli 5 i na Rysunku 2. Sieć bez warstw ukrytych, czyli klasyfikator liniowy, osiąga 90,69% i jest wyraźnie najsłabsza. Zwiększanie liczby neuronów jednej warstwy ukrytej poprawia wynik: z 92,70% dla 32 neuronów do 94,35% dla 128 i 95,16% dla 512, a każdy z tych kroków jest większy od odchylenia standardowego między ziarnami. Dodatkowe warstwy nie poprawiają wyniku względem jednej szerokiej warstwy. Sieci 128-64, 256-128 i 128-128-128 mają od 94,26% do 94,71%, a ich odchylenie standardowe wynosi od 0,73 do 1,15 punktu procentowego, wobec 0,39 dla sieci 512. Różnica między siecią 512 a najlepszą z głębszych, 256-128, wynosi 0,45 punktu procentowego i jest mniejsza niż odchylenie standardowe tej drugiej, więc jest słaba. Wybrano jedną warstwę ukrytą z 512 neuronami.

Tabela 5: Wyniki badania architektury (normalizacja min-max, 5 ziaren). Architekturę podano jako liczby neuronów kolejnych warstw ukrytych.

Warstwy ukryte	Dokładność [%]		Najlepsza
	ucząca	walidacyjna	epoka
brak	$94{,}17 \pm 0{,}33$	$90{,}69 \pm 0{,}86$	17,8
32	$97{,}81 \pm 0{,}69$	$92{,}70 \pm 0{,}59$	11,4
128	$99{,}47 \pm 0{,}65$	$94{,}35 \pm 0{,}61$	10,2
512	$99{,}77 \pm 0{,}13$	$95{,}16 \pm 0{,}39$	6,4
128-64	$98{,}95 \pm 0{,}95$	$94{,}38 \pm 0{,}73$	6,2
256-128	$99{,}19 \pm 0{,}81$	$94{,}71 \pm 1{,}11$	5,8
128-128-128	$98{,}58 \pm 0{,}93$	$94{,}26 \pm 1{,}15$	4,8



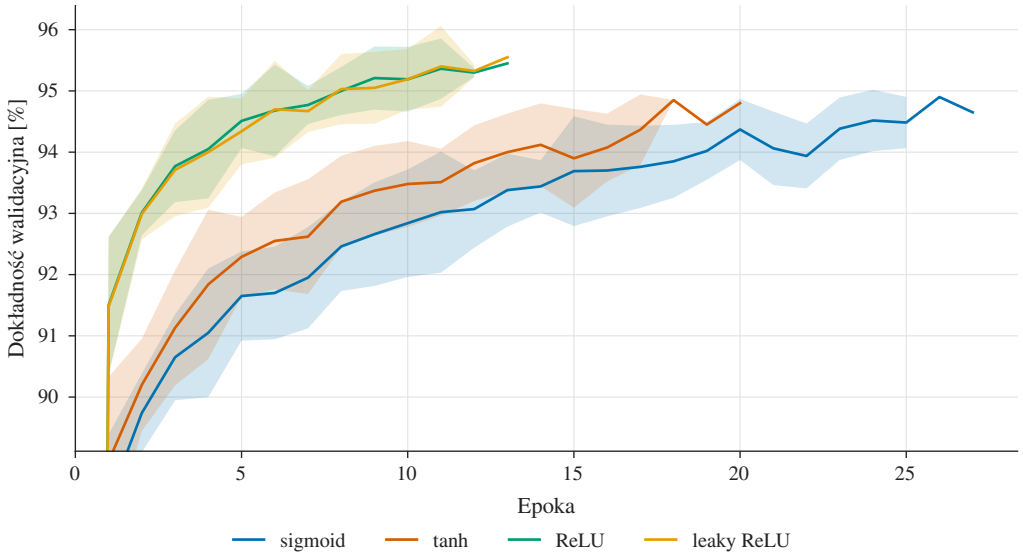
Rysunek 2: Dokładność walidacyjna każdego ziarna (punkty) oraz średnia z odchyleniem standardowym (odcinki) w badaniu architektury.

5.3 Funkcja aktywacji

Wyniki przedstawiono w Tabeli 6 i na Rysunku 3. Sieci z ReLU i leaky ReLU osiągają od 1,04 do 1,15 punktu procentowego większą dokładność walidacyjną niż sieci z funkcją sigmoidalną i tanh, czyli więcej niż odchylenie standardowe między ziarnami, więc efekt jest mocny. Osiągają też minimum straty walidacyjnej szybciej, średnio w epoce 6,4, wobec 12,0 dla tanh i 18,8 dla funkcji sigmoidalnej. Dokładność ucząca wszystkich czterech wariantów jest prawie taka sama (od 99,69% do 99,77%). ReLU i leaky ReLU różnią się o 0,04 punktu procentowego, czyli słabo. Wybrano ReLU.

Tabela 6: Wyniki badania funkcji aktywacji (sieć 512, 5 ziaren). Funkcja sigmoidalna i tanh z inicjalizacją Xaviera, ReLU i leaky ReLU z inicjalizacją He.

Aktywacja	Dokładność [%]		Najlepsza
	ucząca	walidacyjna	epoka
sigmoidalna	$99{,}69 \pm 0{,}35$	$94{,}08 \pm 0{,}65$	18,8
tanh	$99{,}77 \pm 0{,}24$	$94{,}01 \pm 0{,}56$	12,0
ReLU	$99{,}77 \pm 0{,}13$	$95{,}16 \pm 0{,}39$	6,4
leaky ReLU	$99{,}76 \pm 0{,}14$	$95{,}12 \pm 0{,}48$	6,4



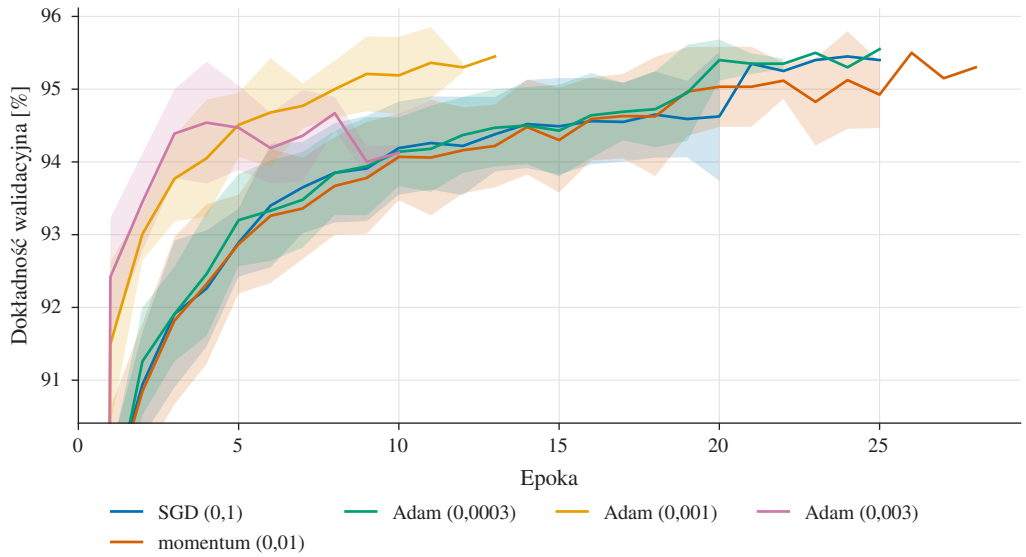
Rysunek 3: Dokładność walidacyjna po kolejnych epokach w badaniu funkcji aktywacji: średnia po ziarnach z pasem jednego odchylenia standardowego. W późnych epokach średnia obejmuje tylko trwające jeszcze uczenia.

5.4 Optymalizator

Wyniki przedstawiono w Tabeli 7 i na Rysunku 4. Najlepszy jest Adam z $\eta = 0{,}001$, o 0,45 do 0,69 punktu procentowego przed pozostałymi wariantami. Różnice są porównywalne z odchyleniem standardowym między ziarnami, więc efekt jest słaby. SGD, SGD z momentum i Adam z $\eta = 0{,}0003$ dają podobne wyniki, ale osiągają minimum straty walidacyjnej dopiero średnio w epoce od 15,2 do 17,0. Adam z $\eta = 0{,}003$ osiąga je najwcześniej, w epoce 3,8. Jako jedyny ma też wyraźnie niższą dokładność uczącą, 98,79%, wobec co najmniej 99,77% dla pozostałych. Na Rysunku 4 jego dokładność walidacyjna rośnie najszybciej w pierwszych epokach, a potem przestaje rosnąć. Wybrano Adama z $\eta = 0{,}001$.

Tabela 7: Wyniki badania optymalizatora (sieć 512 z ReLU, 5 ziaren). W nawiasach współczynnik uczenia η, dla SGD z momentum $\mu = 0{,}9$.

Optymalizator	Dokładność [%]		Najlepsza
	ucząca	walidacyjna	epoka
SGD (0,1)	$99{,}77 \pm 0{,}11$	$94{,}54 \pm 0{,}66$	15,4
SGD z momentum (0,01)	$99{,}78 \pm 0{,}23$	$94{,}47 \pm 0{,}79$	17,0
Adam (0,0003)	$99{,}80 \pm 0{,}22$	$94{,}59 \pm 0{,}73$	15,2
Adam (0,001)	$99{,}77 \pm 0{,}13$	$95{,}16 \pm 0{,}39$	6,4
Adam (0,003)	$98{,}79 \pm 0{,}66$	$94{,}71 \pm 0{,}56$	3,8



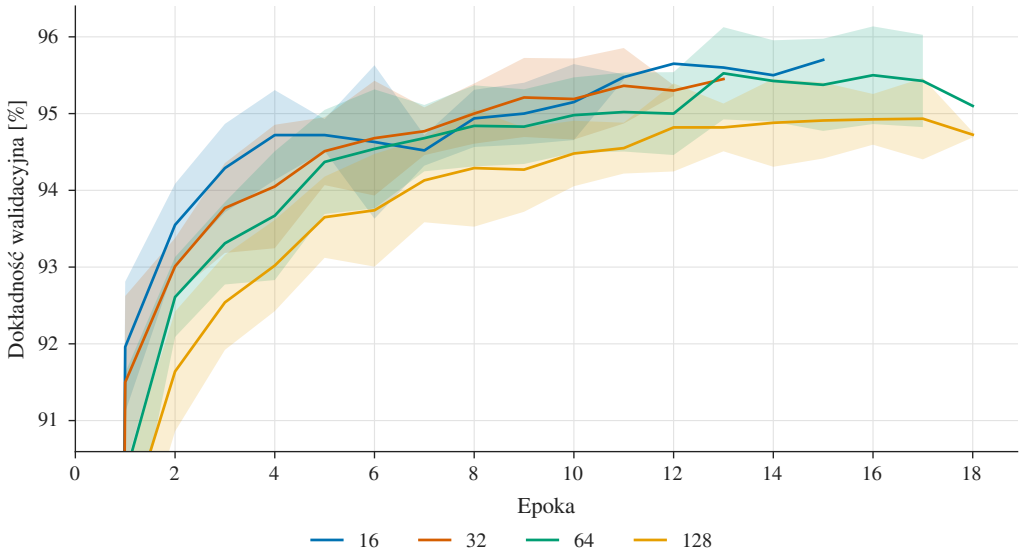
Rysunek 4: Dokładność walidacyjna po kolejnych epokach w badaniu optymalizatora: średnia po ziarnach z pasem jednego odchylenia standardowego. W nawiasach współczynnik uczenia. W późnych epokach średnia obejmuje tylko trwające jeszcze uczenia.

5.5 Rozmiar paczki

Wyniki przedstawiono w Tabeli 8 i na Rysunku 5. Paczka 32 daje największą średnią dokładność walidacyjną, ale przewaga nad pozostałymi rozmiarami wynosi od 0,24 do 0,35 punktu procentowego i jest mniejsza niż odchylenie standardowe między ziarnami, więc efekt jest słaby. Mniejsza paczka oznacza więcej kroków optymalizatora w epoce, więc minimum straty walidacyjnej przypada wcześniej: średnio w epoce 5,2 dla paczki 16 i 11,8 dla paczki 128. Wybrano paczkę 32.

Tabela 8: Wyniki badania rozmiaru paczki (sieć 512 z ReLU, Adam z $\eta = 0{,}001$, 5 ziaren).

Paczka	Dokładność [%]		Najlepsza
	ucząca	walidacyjna	epoka
16	$99{,}10 \pm 0{,}93$	$94{,}81 \pm 0{,}79$	5,2
32	$99{,}77 \pm 0{,}13$	$95{,}16 \pm 0{,}39$	6,4
64	$99{,}78 \pm 0{,}21$	$94{,}92 \pm 0{,}58$	9,0
128	$99{,}91 \pm 0{,}07$	$94{,}83 \pm 0{,}46$	11,8



Rysunek 5: Dokładność walidacyjna po kolejnych epokach w badaniu rozmiaru paczki: średnia po ziarnach z pasem jednego odchylenia standardowego. W późnych epokach średnia obejmuje tylko trwające jeszcze uczenia.

5.6 Konfiguracja wybrana w strojeniu

Wybory wszystkich badań zestawiono w Tabeli 9. Tylko w badaniach architektury i funkcji aktywacji wybrany poziom wyprzedza część pozostałych o więcej niż odchylenie standardowe między ziarnami. W pozostałych badaniach różnice są słabe i inny zestaw ziaren mógłby wskazać inny poziom. Konfiguracja końcowa to sieć 784-512-10 z ReLU i inicjalizacją He, normalizacja min-max, Adam z $\eta = 0{,}001$ i paczka 32 (Tabela 3).

Tabela 9: Poziomy wybrane w badaniach strojenia i drugi najlepszy poziom każdego badania. Dokładność walidacyjna jako średnia i odchylenie standardowe po 5 ziarnach.

Badanie	Wybrany poziom	Dokładność [%]	Drugi poziom	Dokładność [%]
normalizacja wejść	min-max	$94{,}35 \pm 0{,}61$	standaryzacja	$93{,}90 \pm 0{,}18$
architektura	512	$95{,}16 \pm 0{,}39$	256-128	$94{,}71 \pm 1{,}11$
funkcja aktywacji	ReLU	$95{,}16 \pm 0{,}39$	leaky ReLU	$95{,}12 \pm 0{,}48$
optymalizator	Adam (0,001)	$95{,}16 \pm 0{,}39$	Adam (0,003)	$94{,}71 \pm 0{,}56$
rozmiar paczki	32	$95{,}16 \pm 0{,}39$	64	$94{,}92 \pm 0{,}58$

6 Sieć końcowa

W rozdziale przedstawiono dokładność konfiguracji wybranej w strojeniu na zbiorze testowym dla pięciu ziaren oraz przebieg uczenia i błędy zgłoszonej sieci.

6.1 Wyniki dla pięciu ziaren

Wyniki uczenia konfiguracji końcowej na pełnym zbiorze uczącym (podrozdział 4.2) przedstawiono w Tabeli 10. Średnia dokładność testowa wynosi $(97{,}91 \pm 0{,}15)\%$, a wyniki pięciu ziaren mieszczą się w przedziale od 97,74% do 98,12%. Uczenie kończyło się po 8 do 12 epokach, a sieć zwracana przez wczesne zatrzymanie pochodziła z epoki od 3 do 7. Dokładność walidacyjna, $(97{,}79 \pm 0{,}08)\%$, jest bliska testowej. W strojeniu ta sama konfiguracja osiągała na zbiorze walidacyjnym $(95{,}16 \pm 0{,}39)\%$ (Tabela 9), ucząc się na 8000 zamiast 54 000 obrazów.

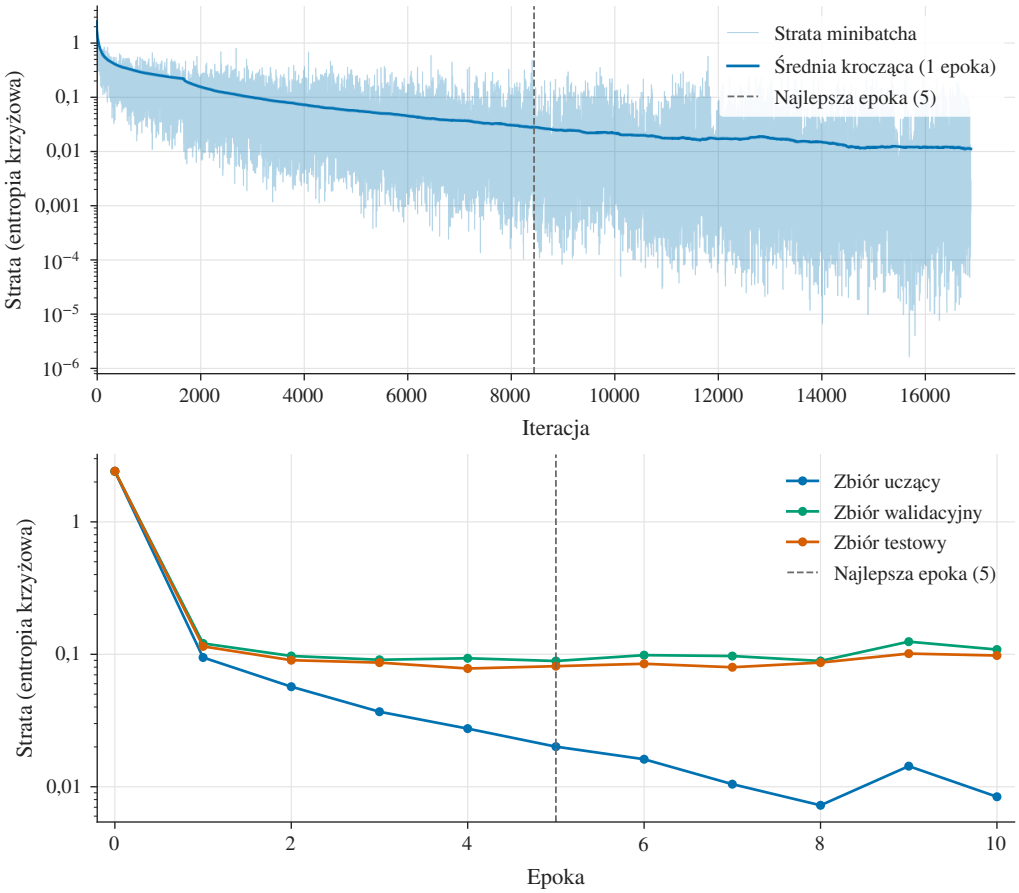
Tabela 10: Wyniki uczenia konfiguracji końcowej na pełnym zbiorze uczącym dla pięciu ziaren. Najlepsza epoka to epoka najmniejszej straty walidacyjnej, z której pochodzi sieć.

Ziarno	Epoki	Najlepsza	Dokładność [%]		
		epoka	ucząca	walidacyjna	testowa
1	10	5	99,34	97,73	97,74
2	12	7	99,64	97,90	98,12
3	8	3	98,96	97,83	97,95
4	9	4	99,29	97,70	97,80
5	10	5	99,44	97,78	97,92
średnia	9,8	4,8	$99{,}33 \pm 0{,}25$	$97{,}79 \pm 0{,}08$	$97{,}91 \pm 0{,}15$

6.2 Zgłoszona sieć

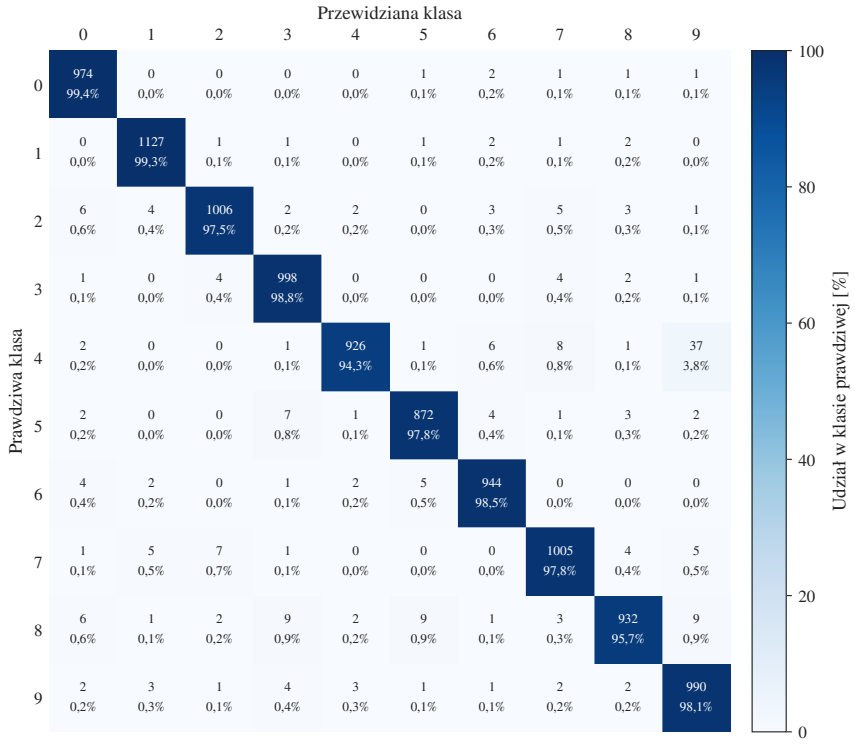
Zgłoszona sieć to uczenie z ziarnem 1, ustalonym przed uczeniem (podrozdział 4.2). Sieć 784-512-10 ma 407 050 parametrów. Uczenie zakończyło się po 10 epokach (16 880 iteracji), a wczesne zatrzymanie przywróciło sieć z epoki 5. Jej dokładność testowa wynosi 97,74%, co odpowiada 226 błędnie sklasyfikowanym obrazom spośród 10 000. Jest to najniższy wynik spośród pięciu ziaren z Tabeli 10.

Przebieg straty przedstawiono na Rysunku 6. Strata ucząca maleje do epoki 8, z 0,0201 w epoce 5 do 0,0072, a strata walidacyjna osiąga najmniejszą wartość, 0,089 02, w epoce 5, a w kolejnych epokach waha się bez dalszego spadku. W epoce 8 dokładność walidacyjna wynosiła 98,05%, ale strata walidacyjna, 0,089 10, była nieznacznie większa niż w epoce 5. Ponieważ wczesne zatrzymanie kieruje się stratą, zwrócona sieć pochodzi z epoki 5 i ma dokładność walidacyjną 97,73%.



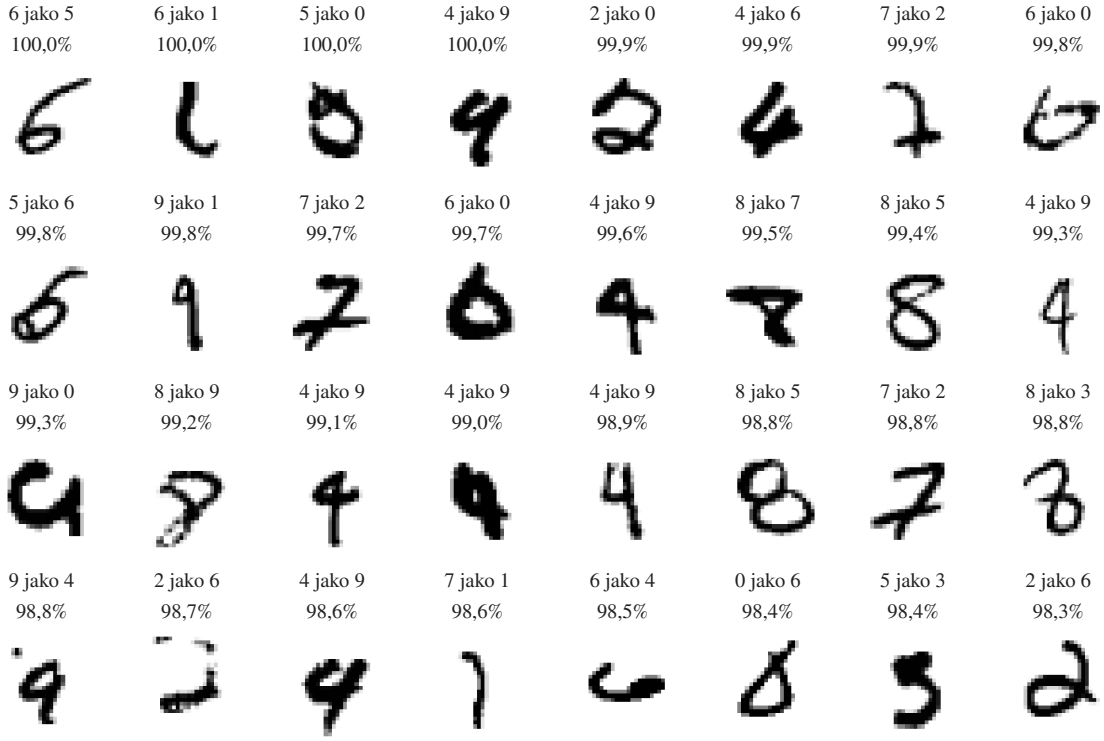
Rysunek 6: Przebieg straty zgłoszonej sieci w skali logarytmicznej. Górny wykres: strata kolejnych paczek i jej średnia krocząca z okna jednej epoki. Dolny wykres: strata na zbiorach uczącym, walidacyjnym i testowym po każdej epoce. Linia przerywana oznacza epokę, z której pochodzi zwrócona sieć.

Macierz pomyłek na zbiorze testowym przedstawiono na Rysunku 7. Najlepiej rozpoznawane są cyfry 0 i 1 (99,39% i 99,30% poprawnych decyzji), a najsłabiej 4 (94,30%) i 8 (95,69%). Najczęstszą pomyłką jest klasyfikacja czwórki jako dziewiątki (37 obrazów, 3,8% czwórek). Kolejne pomyłki są co najmniej czterokrotnie rzadsze: ósemka jako 9, 5 i 3 (po 9 obrazów) oraz czwórka jako 7 (8 obrazów).



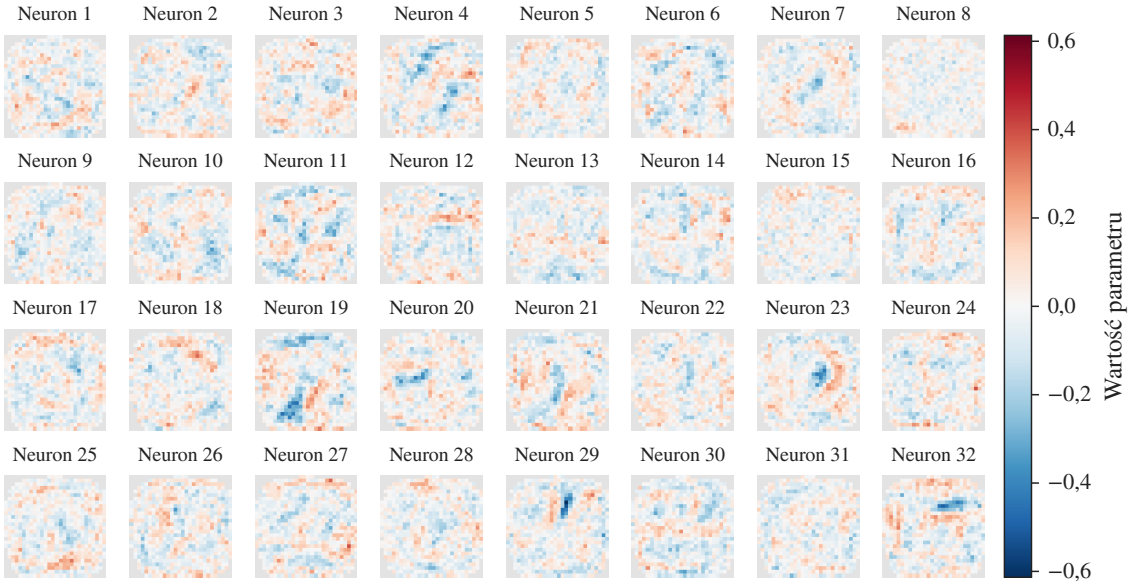
Rysunek 7: Macierz pomyłek zgłoszonej sieci na zbiorze testowym: liczba obrazów i odsetek w wierszu klasy prawdziwej.

Na Rysunku 8 pokazano 32 błędnie sklasyfikowane obrazy testowe, którym sieć przypisała największe prawdopodobieństwo błędnej klasy. Spośród 226 błędów 19 ma prawdopodobieństwo przewidzianej klasy większe niż 0,99, a 65 większe niż 0,9. Mediana tego prawdopodobieństwa wynosi dla błędów 0,77. Wśród pokazanych obrazów są cyfry o nietypowym kształcie oraz cyfry przypominające przewidzianą klasę, np. czwórki z zamkniętą górną częścią sklasyfikowane jako 9.



Rysunek 8: Błędnie sklasyfikowane obrazy testowe o największym prawdopodobieństwie przewidzianej klasy. Nad obrazem podano klasę prawdziwą, klasę przewidzianą i jej prawdopodobieństwo.

Wagi łączące piksele obrazu z pierwszymi 32 spośród 512 neuronów warstwy ukrytej przedstawiono jako obrazy 28×28 na Rysunku 9. Część neuronów ma wyraźne, lokalne skupiska wag o jednym znaku, układające się w fragmenty pociągnięć, a u pozostałych wagi nie tworzą widocznej struktury. Szarym kolorem oznaczono 72 piksele, które mają wartość 0 we wszystkich 54 000 obrazach uczących. Zgodnie z podrozdziałem 2.1 ich wagi nie otrzymują gradientu i pozostają równe wartościom początkowym.



Rysunek 9: Wagi pierwszej warstwy zgłoszonej sieci dla pierwszych 32 neuronów warstwy ukrytej, przedstawione jako obrazy 28×28 we wspólnej skali barw. Szare piksele są stałe w części uczącej.

7 Podsumowanie i wnioski

Perceptron wielowarstwowy z części pierwszej projektu zastosowano do rozpoznawania cyfr MNIST, zmieniając wyłącznie jego parametry. Konfigurację dobrano w pięciu badaniach strojenia na podzbiorze zbioru uczącego, a wybraną konfigurację nauczono na pełnym zbiorze uczącym i oceniono na zbiorze testowym. W rozdziale zebrano najważniejsze wnioski oraz ograniczenia przeprowadzonych badań.

7.1 Wnioski

Strojenie

- Liczba neuronów jednej warstwy ukrytej wyraźnie wpływa na wynik: dokładność walidacyjna rośnie z 92,70% dla 32 neuronów do 94,35% dla 128 i 95,16% dla 512. Dodatkowe warstwy ukryte nie poprawiają wyniku względem jednej szerokiej warstwy i zwiększają rozrzut między ziarnami, z odchyleniem standardowym do 1,15 punktu procentowego wobec 0,39 dla sieci 512 (podrozdział 5.2).
- Sieci z ReLU i leaky ReLU osiągają od 1,04 do 1,15 punktu procentowego większą dokładność walidacyjną niż sieci z funkcją sigmoidalną i tanh, czyli więcej niż rozrzut między ziarnami. Osiągają też minimum straty walidacyjnej w mniejszej liczbie epok (podrozdział 5.3).
- Normalizacja wejść, optymalizator i rozmiar paczki dają różnice porównywalne z rozrzutem między ziarnami. Wybrane poziomy, czyli normalizacja min-max, Adam z $\eta = 0{,}001$ i paczka 32, są najlepsze średnio, ale inny zestaw ziaren mógłby wskazać inne (podrozdział 5.6).
- Standaryzacja nadaje rzadko niezerowym pikselom duże wartości wejść, na części uczącej do około 89, co jest zgodne z jej słabszym wynikiem od normalizacji min-max (podrozdział 5.1).

Sieć końcowa

- Sieć 784-512-10 z ReLU, normalizacją min-max, optymalizatorem Adam z $\eta = 0{,}001$ i paczką 32, uczona na pełnym zbiorze uczącym, osiąga na zbiorze testowym $(97{,}91 \pm 0{,}15)\%$ dla 5 ziaren. Zgłoszona sieć, z ziarnem ustalonym przed uczeniem, osiąga 97,74% (podrozdział 6.1).
- Większy zbiór uczący poprawia wynik tej samej konfiguracji: dokładność walidacyjna rośnie z 95,16% przy 8000 obrazach uczących do 97,79% przy 54 000.
- Sieć przeucza się także na pełnym zbiorze: dokładność ucząca wynosi 99,33%, a strata walidacyjna przestaje maleć po kilku epokach. Wczesne zatrzymanie kończy uczenie po 8 do 12 epokach (podrozdział 6.2).
- Najczęstszą pomyłką zgłoszonej sieci jest klasyfikacja czwórki jako dziewiątki (37 z 226 błędów), a najsłabiej rozpoznawane są cyfry 4 i 8.

7.2 Ograniczenia

Wnioski obowiązują w warunkach, w których przeprowadzono badania:

- każde badanie zmieniało jeden czynnik, a badania przeprowadzono kolejno, więc wybory zależą od kolejności badań i nie wiadomo, czy czynniki na siebie oddziałują, np. czy sieć z funkcją tanh nie wymagałaby innego współczynnika uczenia,
- strojenie przeprowadzono na 8000 obrazach uczących, a sieć końcową uczono na 54 000. Nie sprawdzono, czy przy większym zbiorze uczącym byłyby lepsze inne poziomy, np. głębsze sieci, które na podzbiorze nie przewyższały jednej szerokiej warstwy,
- każdy wariant uczono dla 5 ziaren, a każdy czynnik miał kilka poziomów. Przy różnicach porównywalnych z rozrzutem między ziarnami wybór poziomu jest niepewny, a poziomy spoza badanych siatek, np. inne współczynniki uczenia SGD, nie zostały sprawdzone.

Bibliografia

[1] Adam Grącikowski. *Klasyfikacja i regresja z użyciem perceptronu wielowarstwowego*. Raport z projektu, przedmiot Sieci neuronowe. Warszawa: Politechnika Warszawska, Wydział Matematyki i Nauk Informacyjnych, 2026.

[2] Yann LeCun, Léon Bottou, Yoshua Bengio i Patrick Haffner. „Gradient-based learning applied to document recognition". W: *Proceedings of the IEEE* 86.11 (1998), s. 2278–2324. DOI: 10.1109/5.726791.

[3] Ian Goodfellow, Yoshua Bengio i Aaron Courville. *Deep Learning*. Cambridge, MA: MIT Press, 2016. URL: https://www.deeplearningbook.org.

[4] Diederik P. Kingma i Jimmy Ba. „Adam: A Method for Stochastic Optimization". W: *3rd International Conference on Learning Representations (ICLR)*. 2015. arXiv: 1412.6980.

A Odtworzenie wyników

Do odtworzenia wyników potrzebne są kompilator języka Rust w wersji 1.88.0, wskazanej w pliku `rust-toolchain.toml`, oraz Python w wersji co najmniej 3.13 z menedżerem pakietów `uv`. Ścieżki w plikach konfiguracyjnych są względne, dlatego polecenia uruchamia się z katalogu głównego repozytorium. Polecenia przedstawiono na Listingu A.1. Pierwsze z nich pobiera zbiór MNIST i zapisuje go w plikach CSV, kolejne uczą zgłoszoną sieć i tworzą jej wykresy, a ostatnie powtarza wszystkie badania części drugiej.

Listing A.1 Polecenia odtwarzające wyniki części drugiej, uruchamiane z katalogu głównego repozytorium.

```
# pobranie zbioru MNIST i zapis w plikach CSV
uv run --project src/analysis src/analysis/main.py mnist

# zgłoszona sieć: uczenie i wykresy
cargo run --release --manifest-path src/compute/Cargo.toml -- \
    train data/experiments/mnist/final
uv run --project src/analysis src/analysis/main.py \
    plot data/experiments/mnist/final

# badania strojenia i uczenie końcowe dla pięciu ziaren (PowerShell 7)
pwsh -File scripts/run-studies.ps1 -Jobs 1 `
    data/experiments/mnist/tuning-normalization `
    data/experiments/mnist/tuning-architectures `
    data/experiments/mnist/tuning-activations `
    data/experiments/mnist/tuning-optimizers `
    data/experiments/mnist/tuning-batch-sizes `
    data/experiments/mnist/final-seeds
```

Wszystkie parametry uczenia zgłoszonej sieci, łącznie z ziarnem generatora `training.seed = 1`, zawiera plik `data/experiments/mnist/final/config.toml`, przedstawiony na Listingu A.2.

Listing A.2 Plik `config.toml` zgłoszonej sieci.

```toml
task = "classification"

[data]
train = "data/datasets/mnist/data.mnist.train.60000.csv"
test = "data/datasets/mnist/data.mnist.test.10000.csv"  # only for the final evaluation
target = "label"
input_normalization = "min_max"    # per pixel, from the training samples
target_normalization = "none"
validation_fraction = 0.1          # 54000 for training, 6000 for early stopping

[model]
hidden_layers = [512]              # 784 -> 512 -> 10
bias = true
hidden_activation = { kind = "relu" }
output_activation = "softmax"
init = { kind = "he" }

[optimizer]
kind = "adam"
learning_rate = 0.001

[training]
loss = "cross_entropy"
epochs = 50
batch_size = 32
seed = 1
early_stopping = { patience = 5 }  # on the validation loss; restores the best epoch

[logging]
loss_every = 1                     # in iterations (batches); 1688 iterations per epoch
weights_every = 1688               # one snapshot per epoch
max_weights_per_layer = 64

[output]
grid_resolution = 100              # not used: no prediction grid for more than 2 features
grid_margin = 0.1
```

Konfiguracje i wyniki znajdują się w następujących miejscach:

- konfiguracje badań strojenia: `data/experiments/mnist/tuning-<czynnik>/study.toml`,
- konfiguracja uczenia końcowego dla pięciu ziaren: `data/experiments/mnist/final-seeds/study.toml`,
- zestawienia badań: katalog `results/` badania,
- wagi i biasy zgłoszonej sieci: `data/experiments/mnist/final/artifacts/model/`,
- metadane zgłoszonej sieci z kopią konfiguracji, wersją kodu i końcowymi metrykami: `data/experiments/mnist/final/artifacts/metadata.json`,
- wykresy zgłoszonej sieci: `data/experiments/mnist/final/plots/`.

Polecenie `train` zastępuje zawartość katalogu `artifacts/`. Ponowne uczenie daje wagi identyczne z zapisanymi, więc wynik można porównać z wersją przechowywaną w repozytorium.